



UNIVERSIDAD PRIVADA DE TACNA
FACULTAD DE INGENIERÍA
Escuela Profesional de Ingeniería de Sistemas

PROYECTO DE UNIDAD N° 03

“Menor error en Validación Cruzada”

Curso: MACHINE LEARNING

Docente: Ing. ISRAEL NAZARETH CHAPARRO CRUZ

Diego Fernando Castillo Mamani (2022073895)

Cesar Nikolas Camac Melendez (2022074262)

Sergio Alberto Colque Ponce (2022073503)

Tacna – Perú
2026



ÍNDICE

I. INFORMACIÓN GENERAL	4
- Objetivos	4
- Equipos, materiales, programas y recursos utilizados	4
II. MARCO TEORICO	4
III. PROCEDIMIENTO	5
IV. ANALISIS E INTERPRETACION DE RESULTADOS	7
V. CUESTIONARIO	8
CONCLUSIONES	8
RECOMENDACIONES	8
BIBLIOGRAFÍA	8
WEBGRAFIA	8



INFORME DE LABORATORIO N° 03

TEMA: Menor error en Validación Cruzada

Descripción del problema (clasificación)

Las enfermedades cardíacas representan una de las principales causas de muerte en el mundo, por lo que su detección temprana es fundamental. En este proyecto se busca predecir la presencia o ausencia de una enfermedad cardíaca utilizando datos clínicos de pacientes del dataset Heart Disease. Se trata de un problema de clasificación binaria supervisada, donde la variable target indica si el paciente presenta (1) o no presenta (0) la enfermedad. El objetivo es aplicar técnicas de Machine Learning para identificar patrones en los datos y apoyar la toma de decisiones médicas.

Descripción del conjunto de datos (info, describe, value_counts(), hist).

1. df.info() — El dataset contiene 1025 registros y 14 columnas, todas numéricas (13 enteras y 1 flotante: oldpeak), sin valores nulos en ninguna columna.

```
[4]
✓ 0s # Información general del dataset
df.info()

... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 1025 entries, 0 to 1024
Data columns (total 14 columns):
#   Column      Non-Null Count  Dtype
---  -
0    age        1025 non-null   int64
1    sex        1025 non-null   int64
2    cp         1025 non-null   int64
3    trestbps   1025 non-null   int64
4    chol       1025 non-null   int64
5    fbs        1025 non-null   int64
6    restecg    1025 non-null   int64
7    thalach    1025 non-null   int64
8    exang      1025 non-null   int64
9    oldpeak    1025 non-null   float64
10   slope      1025 non-null   int64
11   ca         1025 non-null   int64
12   thal       1025 non-null   int64
13   target     1025 non-null   int64
dtypes: float64(1), int64(13)
memory usage: 112.2 KB
```

2. `df.describe()` — Las variables presentan rangos y escalas muy distintas (por ejemplo, age de 29 a 77 años vs. chol de 0 a 564), lo que sugiere la necesidad de normalizar o estandarizar los datos antes de modelar.

```
[5]
✓ 0s # Estadísticas descriptivas
df.describe()
```


	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
count	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000
mean	54.434146	0.695610	0.942439	131.611707	246.000000	0.149268	0.529756	149.114146	0.336585	1.071512	1.385366	0.754146	2.323902	0.513171
std	9.072290	0.460373	1.029641	17.516718	51.59251	0.356527	0.527878	23.005724	0.472772	1.175053	0.617755	1.030798	0.620660	0.500070
min	29.000000	0.000000	0.000000	94.000000	126.00000	0.000000	0.000000	71.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	48.000000	0.000000	0.000000	120.000000	211.00000	0.000000	0.000000	132.000000	0.000000	0.000000	1.000000	0.000000	2.000000	0.000000
50%	56.000000	1.000000	1.000000	130.000000	240.00000	0.000000	1.000000	152.000000	0.000000	0.800000	1.000000	0.000000	2.000000	1.000000
75%	61.000000	1.000000	2.000000	140.000000	275.00000	0.000000	1.000000	166.000000	1.000000	1.800000	2.000000	1.000000	3.000000	1.000000
max	77.000000	1.000000	3.000000	200.000000	564.00000	1.000000	2.000000	202.000000	1.000000	6.200000	2.000000	4.000000	3.000000	1.000000

3. `value_counts()` de `target` — La variable objetivo está bien balanceada: 526 casos positivos (1) y 499 negativos (0), por lo que no se requieren técnicas especiales de balanceo de clases.

```
[6]
✓ 0s # Distribución de la variable objetivo
print(df['target'].value_counts())

... target
1      526
0      499
Name: count, dtype: int64
```

4. Histogramas — La mayoría de variables categóricas (sex, fbs, exang, target) muestran distribuciones binarias claras, mientras que las continuas (age, trestbps, thalach) tienen forma aproximadamente normal o sesgada (chol, oldpeak con cola hacia la derecha).



División del conjunto de datos (puntos extra: estratificada).

Análisis Exploratorio de Datos (solo train_set) incluyendo correlaciones (puntos extra: nuevos atributos con buena correlación).

Deshacerse de los valores NaN.



Eliminación de Outliers (opcional).

Codificación de datos categóricos.

Escalado de características.

Entrenar modelos de clasificación. Analizar los errores del modelo para train_set y test_set (matriz de confusión, accuracy, precision, recall, f1-score).

Selección y evaluación de modelos (al menos 2).

Conclusiones finales.